

Персептрон

ЛЕКЦИЯ №2





1. Персептрон Розенблата.
2. Обучение однослойного персептрона.
3. Теорема сходимости персептрона.
4. Линейная регрессия.

1. Персептрон Розенблата.
2. Обучение однослойного персептрона.
3. Теорема сходимости персептрона.
4. Линейная регрессия.


Персептрон Розенблата



Математическая модель нейрона



Математическая модель нейрона




$$\sigma \left(\sum_{i=0}^m x_i w_i \right) = \sigma (\mathbf{x}^T \mathbf{w}) = \hat{y}$$

$$\sigma(z) = \begin{cases} 0, & z \leq 0 \\ 1, & z > 0 \end{cases}$$

$$w_0 = -\theta$$

Математическая модель нейрона



$$\sigma \left(\sum_{i=0}^m x_i w_i \right) = \sigma(\mathbf{x}^T \mathbf{w}) = \hat{y}$$


$$\sigma(z) = \begin{cases} 0, & z - \theta \leq 0 \\ 1, & z - \theta > 0 \end{cases}$$

$$w_0 = -\theta$$

1. Персептрон Розенблата.
- 2. Обучение однослойного персептрона.**
3. Теорема сходимости персептрона.
4. Линейная регрессия.

Обучение персептрона

Цель персептрона: корректное отнесение входного множества к одному из 2-х классов.




Однослойный персептрон

Цель персептрона: корректное отнесение входного множества к одному из 2-х классов.

$$\mathcal{L}(\mathbf{w}, b) = \sum_i \frac{1}{2} (\hat{y}^{[i]} - y^{[i]})^2$$


$$\hat{y} = \sigma(\mathbf{w}^T \mathbf{x} + b) = \begin{cases} 0, & \mathbf{w}^T \mathbf{x} + b \leq 0 \\ 1, & \mathbf{w}^T \mathbf{x} + b > 0 \end{cases}$$



Алгоритм обучения персептрона

$$\mathcal{D} = (\langle \mathbf{x}^{[1]}, y^{[1]} \rangle, \langle \mathbf{x}^{[2]}, y^{[2]} \rangle, \dots, \langle \mathbf{x}^{[n]}, y^{[n]} \rangle) \in (\mathbb{R}^m \times \{0, 1\})^n$$

1. Initialize $\mathbf{w} := 0^m$
2. For every training epoch:
 - A. For every $\langle \mathbf{x}^{[i]}, y^{[i]} \rangle \in \mathcal{D}$:
 - (a) $\hat{y}^{[i]} := \sigma(\mathbf{x}^{[i]T} \mathbf{w})$
 - (b) $err := (y^{[i]} - \hat{y}^{[i]})$
 - (c) $\mathbf{w} := \mathbf{w} + err \times \mathbf{x}^{[i]}$



1. Персептрон Розенблата.
2. Обучение однослойного персептрона.
3. Теорема сходимости персептрона.
4. Линейная регрессия.

Теорема сходимости для персептрона

$$\mathcal{D} = (\langle \mathbf{x}^{[1]}, y^{[1]} \rangle, \langle \mathbf{x}^{[2]}, y^{[2]} \rangle, \dots, \langle \mathbf{x}^{[n]}, y^{[n]} \rangle) \in (\mathbb{R}^m \times \{0, 1\})^n$$

$$\forall y^{[i]} \in \mathcal{D}_1 : y^{[i]} = 1 \quad \text{and} \quad \mathcal{D}_1 \cup \mathcal{D}_2 = \mathcal{D}$$

$$\forall y^{[i]} \in \mathcal{D}_2 : y^{[i]} = 0$$

$$\forall \mathbf{x}^{[i]} \in \mathcal{D}_1 : \mathbf{w}^T \mathbf{x}^{[i]} > 0$$

$$\forall \mathbf{x}^{[i]} \in \mathcal{D}_2 : \mathbf{w}^T \mathbf{x}^{[i]} \leq 0$$

Алгоритм адаптации персептрона сформулируем с следующим виде

$$\mathbf{w}^{[i+1]} = \mathbf{w}^{[i]} + \mathbf{x}^{[i]} \quad \text{if} \quad (\mathbf{w}^{[i]})^T \mathbf{x}^{[i]} \leq 0, \mathbf{x}^{[i]} \in \mathcal{D}_1$$

$$\mathbf{w}^{[i+1]} = \mathbf{w}^{[i]} - \mathbf{x}^{[i]} \quad \text{if} \quad (\mathbf{w}^{[i]})^T \mathbf{x}^{[i]} > 0, \mathbf{x}^{[i]} \in \mathcal{D}_2$$

Теорема сходимости для персептрона

$$\mathbf{w}^{[i+1]} = \mathbf{w}^{[0]} + \mathbf{x}^{[1]} + \dots + \mathbf{x}^{[i]}$$

Умножим обе стороны на $\mathbf{w}^*$

$$(\mathbf{w}^*)^T \mathbf{w}^{[i+1]} = (\mathbf{w}^*)^T \mathbf{x}^{[1]} + \dots + (\mathbf{w}^*)^T \mathbf{x}^{[i]}$$

Пусть $\alpha = \min_{x^{[j]}} (\mathbf{w}^*)^T \mathbf{x}^{[j]}, j = 1, \dots, i$

Тогда $\underbrace{(\mathbf{w}^*)^T \mathbf{w}^{[i+1]}} \geq \alpha i$

Используя неравенство Гучи-Шварца для 2х векторов

$$||\mathbf{w}^*||^2 \cdot ||\mathbf{w}^{[i+1]}||^2 \geq ((\mathbf{w}^*)^T \mathbf{w}^{[i+1]})^2$$

$$||\mathbf{w}^*||^2 \cdot ||\mathbf{w}^{[i+1]}||^2 \geq (\alpha i)^2$$

Получим нижнюю границу

$$||\mathbf{w}^{[i+1]}||^2 \geq \frac{\alpha^2 i^2}{||\mathbf{w}^*||^2}$$

Теорема сходимости для персептрона

Рассмотрим равенство

$$\mathbf{w}^{[i+1]} = \mathbf{w}^{[i]} + \mathbf{x}^{[i]} \quad \text{if } (\mathbf{w}^{[i]})^T \mathbf{x}^{[i]} \leq 0, \mathbf{x}^{[i]} \in \mathcal{D}_1$$

Вычислим Евклидову норму векторов в двух частях уравнения

$$\begin{aligned} ||\mathbf{w}^{[i+1]}||^2 &= ||\mathbf{w}^{[i]} + \mathbf{x}^{[i]}||^2 \\ &= ||\mathbf{w}^{[i]}||^2 + \underbrace{2(\mathbf{x}^{[i]})^T \mathbf{w}^{[i]}}_{\leq 0} + ||\mathbf{x}^{[i]}||^2 \end{aligned}$$

Тогда

$$||\mathbf{w}^{[i+1]}||^2 \leq ||\mathbf{w}^{[i]}||^2 + ||\mathbf{x}^{[i]}||^2$$

Получим

$$\beta = \max ||\mathbf{x}^{[j]}||^2$$

$$||\mathbf{w}^{[i+1]}||^2 \leq \beta i$$

Теорема сходимости для персептрона

Получим: нижняя граница

верхняя граница

$$||\mathbf{w}^{[i+1]}||^2 \geq \frac{\alpha^2 i^2}{||\mathbf{w}^*||^2}$$

$$||\mathbf{w}^{[i+1]}||^2 \leq \beta i$$

Тогда

$$\beta i \geq ||\mathbf{w}^{[i+1]}||^2 \geq \frac{\alpha^2 i^2}{||\mathbf{w}^*||^2}$$

$$i \leq \frac{\beta ||\mathbf{w}^*||^2}{\alpha^2}$$

Таким образом, количество итераций ограничено, следовательно за конечное число повторений N получим весовые коэффициенты для линейно разделимых множеств объектов.


Теорема сходимости для персептрона

Пусть подмножества векторов обучения линейно разделимы.
Пусть входные сигналы поступают на вход персептрону только из этих подмножеств. Тогда алгоритм обучения персептрона сходится после некоторого числа итераций n_0 в том смысле, что вектор является вектором решения для $n_0 < n_{\max}$

$$\mathbf{w}(n_0) = \mathbf{w}(n_0 + 1) = \mathbf{w}(n_0 + 2) = \dots$$

Теорема сходимости для персептрона

$$\beta i \geq ||\mathbf{w}^{[i+1]}||^2 \geq \alpha^2 i^2$$



Теорема сходимости для персептрона

Положим $||\mathbf{w}^*|| = 1$

$$\beta_i \geq ||\mathbf{w}^{[i+1]}||^2 \geq \frac{\alpha^2 i^2}{||\mathbf{w}^*||^2} \quad \Leftrightarrow \quad \beta_i \geq ||\mathbf{w}^{[i+1]}||^2 \geq \alpha^2 i^2$$

$$i \leq \frac{\beta ||\mathbf{w}^*||^2}{\alpha^2} \quad \Leftrightarrow \quad i \leq \frac{\beta}{\alpha^2}$$

Алгоритм обучения персептрона

Таким образом, алгоритм адаптации вектора весовых коэффициентов $\mathbf{w}(n)$ соответствует *правилу обучения на основе коррекции ошибок* (error-correction learning rule)

$$\mathbf{w}(n + 1) = \mathbf{w}(n) + \eta[d(n) - y(n)]\mathbf{x}(n),$$

где η — *параметр скорости обучения*, а разность $d(n) - y(n)$ выступает в роли *сигнала ошибки*. Параметр скорости обучения является положительной константой, принадлежащей интервалу $0 < \eta \leq 1$. Выбирая значение параметра скорости обучения из этого диапазона, следует учитывать два взаимоисключающих требования

- *Усреднение* (averaging) предыдущих входных сигналов, обеспечивающее устойчивость оценки вектора весов, требует малых значений η .
- *Быстрая адаптация* (fast adaptation) к реальным изменениям распределения процесса, отвечающего за формирование векторов входного сигнала $\mathbf{x}$, требует больших значений η .

Алгоритм обучения персептрона

1. Инициализация

Пусть $\mathbf{w}(0)=\mathbf{0}$. Последующие вычисления выполняются для шагов $n = 1, 2, \dots$.

2. Активация

На шаге n активируем персептрон, используя вектор $\mathbf{x}(n)$ с вещественными компонентами и желаемый отклик $d(n)$.

3. Вычисление фактического ответа

Вычисляем фактический отклик персептрона:

$$y(n) = \text{sgn}(\mathbf{w}^T(n)\mathbf{x}(n)),$$

где $\text{sgn}(\cdot)$ — функция вычисления знака аргумента.

4. Адаптация вектора весов

Изменяем вектор весов персептрона:

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \eta[d(n) - y(n)]\mathbf{x}(n),$$

где

$$d(n) = \begin{cases} +1, & \text{если } \mathbf{x}(n) \in \mathbf{C}_1, \\ -1, & \text{если } \mathbf{x}(n) \in \mathbf{C}_2. \end{cases}$$

5. Продолжение

Увеличиваем номер итерации n на единицу и возвращаемся к п. 2 алгоритма.

Алгоритм обучения персептрона

1. Инициализация

Пусть $\mathbf{w}(0)=\mathbf{0}$. Последующие вычисления выполняются для шагов $n = 1, 2, \dots$.

2. Активация

На шаге n активируем персептрон, используя вектор $\mathbf{x}(n)$ с вещественными компонентами и желаемый отклик $d(n)$.

3. Вычисление фактического ответа

Вычисляем фактический отклик персептрона:

$$y(n) = \text{sgn}(\mathbf{w}^T(n)\mathbf{x}(n)),$$

где $\text{sgn}(\cdot)$ — функция вычисления знака аргумента.

4. Адаптация вектора весов

Изменяем вектор весов персептрона:

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \eta[d(n) - y(n)]\mathbf{x}(n),$$

где

$$d(n) = \begin{cases} +1, & \text{если } \mathbf{x}(n) \in \mathbf{C}_1, \\ -1, & \text{если } \mathbf{x}(n) \in \mathbf{C}_2. \end{cases}$$


5. Продолжение

Увеличиваем номер итерации n на единицу и возвращаемся к п. 2 алгоритма.

Проблемы однослойного персептрона

1. Линейный классификатор.
2. Двоичный классификатор (XOR проблема)
3. Классификация только линейно разделимых классов

Алгоритм обучения однослойного персептрона



$$\sigma \left(\sum_{i=1}^m x_i w_i + b \right) = \sigma (\mathbf{x}^T \mathbf{w} + b) = \hat{y}$$

$$\sigma(z) = \begin{cases} 0, & z \leq 0 \\ 1, & z > 0 \end{cases}$$

$$b = -\theta$$

Let $\mathcal{D} = (\langle \mathbf{x}^{[1]}, y^{[1]} \rangle, \langle \mathbf{x}^{[2]}, y^{[2]} \rangle, \dots, \langle \mathbf{x}^{[n]}, y^{[n]} \rangle) \in (\mathbb{R}^m \times \{0, 1\})^n$

1. Initialize $\mathbf{w} := \mathbf{0}^{m-1}$, $\mathbf{b} := 0$
2. For every training epoch:
 - A. For every $\langle \mathbf{x}^{[i]}, y^{[i]} \rangle \in \mathcal{D}$:
 - (a) $\hat{y}^{[i]} := \sigma(\mathbf{x}^{[i]T} \mathbf{w} + b)$
 - (b) $err := (y^{[i]} - \hat{y}^{[i]})$
 - (c) $\mathbf{w} := \mathbf{w} + err \times \mathbf{x}^{[i]}$, $b := b + err$

Модификации алгоритма

$$\mathcal{D} = (\langle \mathbf{x}^{[1]}, y^{[1]} \rangle, \langle \mathbf{x}^{[2]}, y^{[2]} \rangle, \dots, \langle \mathbf{x}^{[n]}, y^{[n]} \rangle) \in (\mathbb{R}^m \times \{0, 1\})^n$$

"On-line" mode

1. Initialize $\mathbf{w} := 0^{m-1}$, $\mathbf{b} := 0$
2. For every training epoch:
 - A. For every $\langle \mathbf{x}^{[i]}, y^{[i]} \rangle \in \mathcal{D}$:
 - (a) Compute output (prediction)
 - (b) Calculate error
 - (c) Update $\mathbf{w}, b$

Batch mode

1. Initialize $\mathbf{w} := 0^{m-1}$, $\mathbf{b} := 0$
2. For every training epoch:
 - A. Initialize $\Delta \mathbf{w} := 0$, $\Delta b := 0$
 - B. For every $\langle \mathbf{x}^{[i]}, y^{[i]} \rangle \in \mathcal{D}$:
 - (a) Compute output (prediction)
 - (b) Calculate error
 - (c) Update $\Delta \mathbf{w}, \Delta b$
 - C. Update $\mathbf{w}, b$:
$$\mathbf{w} := \mathbf{w} + \Delta \mathbf{w}, b := b + \Delta b$$

Модификации алгоритма

$$\mathcal{D} = (\langle \mathbf{x}^{[1]}, y^{[1]} \rangle, \langle \mathbf{x}^{[2]}, y^{[2]} \rangle, \dots, \langle \mathbf{x}^{[n]}, y^{[n]} \rangle) \in (\mathbb{R}^m \times \{0, 1\})^n$$

Minibatch mode

(mix between on-line and batch)

1. Initialize $\mathbf{w} := \mathbf{0}^{m-1}$, $b := 0$
2. For every training epoch:
 - A. Initialize $\Delta \mathbf{w} := \mathbf{0}$, $\Delta b := 0$
 - B. For every $\{\langle \mathbf{x}^{[i]}, y^{[i]} \rangle, \dots, \langle \mathbf{x}^{[i+k]}, y^{[i+k]} \rangle\} \subset \mathcal{D}$:
 - (a) Compute output (prediction)
 - (b) Calculate error
 - (c) Update $\Delta \mathbf{w}, \Delta b$
 - C. Update $\mathbf{w}, b$:
$$\mathbf{w} := \mathbf{w} + \Delta \mathbf{w}, b := b + \Delta b$$

Алгоритм обучения персептрона

Можно оптимизировать процесс обучения персептрона
Алгоритм минимизации среднеквадратической ошибки

$$\mathcal{L}(\mathbf{w}, b) = \sum_i \frac{1}{2} (\hat{y}^{[i]} - y^{[i]})^2 \qquad \hat{y} = \sigma(\mathbf{w}^T \mathbf{x} + b) = \begin{cases} 0, & \mathbf{w}^T \mathbf{x} + b \leq 0 \\ 1, & \mathbf{w}^T \mathbf{x} + b > 0 \end{cases}$$


$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial w_j} &= \frac{\partial}{\partial w_j} \sum_i (\hat{y}^{[i]} - y^{[i]})^2 \\ &= \frac{\partial}{\partial w_j} \sum_i (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]})^2 \\ &= \sum_i 2(\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \frac{\partial}{\partial w_j} (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \\ &= \sum_i 2(\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \sigma'(\mathbf{w}^T \mathbf{x}^{[i]}) \frac{\partial}{\partial w_j} \mathbf{w}^T \mathbf{x}^{[i]} \\ &= \sum_i 2(\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \sigma'(\mathbf{w}^T \mathbf{x}^{[i]}) x_j^{[i]} \end{aligned}$$

Алгоритм обучения персептрона

Алгоритм минимизации среднеквадратической ошибки

$$\mathcal{L}(\mathbf{w}, b) = \sum_i \frac{1}{2} (\hat{y}^{[i]} - y^{[i]})^2$$

$$\hat{y} = \sigma(\mathbf{w}^T \mathbf{x} + b) = \begin{cases} 0, & \mathbf{w}^T \mathbf{x} + b \leq 0 \\ 1, & \mathbf{w}^T \mathbf{x} + b > 0 \end{cases}$$



$$\hat{y} = \sigma(\mathbf{w}^T \mathbf{x} + b) = \begin{cases} \sigma(x) = x \end{cases}$$

1. Персептрон Розенблата.
2. Обучение однослойного персептрона.
3. Теорема сходимости персептрона.
4. **Линейная регрессия.**

Линейная регрессия

Вектора пространств а признаков	Признак 1	...	Признак m	Целевая переменная
1		...		
2				
n				

DataSet

Модель зависимости целевой переменной от признаков:

$$\hat{y} = \sigma(\mathbf{w}^T \mathbf{x} + b) = \begin{cases} 0, & \mathbf{w}^T \mathbf{x} + b \leq 0 \\ 1, & \mathbf{w}^T \mathbf{x} + b > 0 \end{cases}$$

$$L(a, Y) = (a - Y)^2$$

$$Q(W) = \sum_{i=1}^l (a(X_i, W) - Y_i) \rightarrow \min_W$$

- $\vec{y} \in \mathbb{R}^n$ – объясняемая (или целевая) переменная;
- w – вектор параметров модели (в машинном обучении эти параметры часто называют весами);
- X – матрица наблюдений и признаков размерности n строк на $m + 1$ столбцов (включая фиктивную единичную колонку слева) рангом по столбцам: $\text{rank}(X) = m + 1$;

Линейная регрессия

Метод наименьших квадратов (МНК) минимизирует среднеквадратичную ошибку между реальным значением зависимой переменной и прогнозом, выданным моделью.


$$L(a, Y) = (a - Y)^2$$

$$Q(W) = \sum_{i=1}^l (a(X_i, W) - Y_i) \rightarrow \min_W$$

$$a(X_j, W) = w_1 x_{j1} + w_2 x_{j2} + w_0$$

$$\begin{cases} x_{11}w_1 + x_{12}w_2 = Y_1 \\ x_{21}w_1 + x_{22}w_2 = Y_2 \end{cases} \Rightarrow \begin{cases} X_1 W = Y_1 \\ X_2 W = Y_2 \end{cases}$$

$$\begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} \Leftrightarrow XW = Y$$



Решив данную **оптимизационную задачу**, получим:

$$\vec{w} = (X^T X)^{-1} X^T \vec{y}$$

Линейная регрессия

Почему минимизируют среднеквадратичную ошибку?

$$\epsilon_i \sim \mathcal{N}(0, \sigma^2) \quad - \text{предположение}$$

$$\begin{aligned} p(y_i \mid X, \vec{w}) &= \sum_{j=1}^m w_j X_{ij} + \mathcal{N}(0, \sigma^2) \\ &= \mathcal{N}\left(\sum_{j=1}^m w_j X_{ij}, \sigma^2\right) \end{aligned}$$

$$\begin{aligned} \Rightarrow \quad \log p(\vec{y} \mid X, \vec{w}) &= \log \prod_{i=1}^n \mathcal{N}\left(\sum_{j=1}^m w_j X_{ij}, \sigma^2\right) \\ &= \sum_{i=1}^n \log \mathcal{N}\left(\sum_{j=1}^m w_j X_{ij}, \sigma^2\right) \\ &= -\frac{n}{2} \log 2\pi\sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n \left(y_i - \vec{w}^T \vec{x}_i\right)^2 \end{aligned}$$

Линейная регрессия

$$\begin{aligned}\hat{w} &= \arg \max_w p(\vec{y} \mid X, \vec{w}) \\ &= \arg \max_w -\frac{n}{2} \log 2\pi\sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n \left(y_i - \vec{w}^T \vec{x}_i\right)^2 \\ &= \arg \max_w -\frac{1}{2\sigma^2} \sum_{i=1}^n \left(y_i - \vec{w}^T \vec{x}_i\right)^2 \\ &= \arg \max_w -\mathcal{L}(X, \vec{y}, \vec{w})\end{aligned}$$


Максимизация вероятности – это то же самое, что и минимизация среднеквадратичной ошибки!

Линейная регрессия

$$\begin{aligned} Q &= (XW - Y)^2 \rightarrow \min_W \\ (XW - Y)^2 &= (XW - Y)^T (XW - Y) = \\ &= Y^T Y - Y^T XW - W^T X^T Y + W^T X^T XW = \\ &= Y^T Y - 2Y^T XW + W^T X^T XW, \end{aligned}$$

$$\frac{\partial Q}{\partial W} = -2X^T Y + 2X^T XW = 0$$

$$X^T XW = X^T Y \quad W = (X^T X)^{-1} X^T Y$$



Максимизация вероятности – это то же самое, что и минимизация среднеквадратичной ошибки!


Линейная регрессия

$$a(X_j, W) = w_1 x_{j1} + \dots + w_m x_{jm} + w_0$$

$$\begin{cases} x_{11}w_1 + \dots + x_{1m}w_m = Y_1 \\ x_{n1}w_1 + \dots + x_{nm}w_m = Y_n \end{cases} \Rightarrow \begin{cases} X_1 W = Y_1 \\ X_n W = Y_n \end{cases}$$

$$\begin{bmatrix} x_{11} & x_{1m} \\ \dots & \dots \\ x_{n1} & x_{nm} \end{bmatrix} \begin{bmatrix} w_1 \\ \dots \\ w_m \end{bmatrix} = \begin{bmatrix} Y_1 \\ \dots \\ Y_n \end{bmatrix} \Leftrightarrow XW = Y$$

$$X^T X W = X^T Y \quad W = (X^T X)^{-1} X^T Y$$



Решив данную **оптимизационную задачу**, получим:

$$\vec{w} = (X^T X)^{-1} X^T \vec{y}$$

Алгоритм обучения персептрона

Алгоритм минимизации среднеквадратической ошибки

$$\mathcal{L}(\mathbf{w}, b) = \sum_i \frac{1}{2} (\hat{y}^{[i]} - y^{[i]})^2 \qquad \hat{y} = \sigma(\mathbf{w}^T \mathbf{x} + b) = \begin{cases} 0, & \mathbf{w}^T \mathbf{x} + b \leq 0 \\ 1, & \mathbf{w}^T \mathbf{x} + b > 0 \end{cases}$$

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial w_j} &= \frac{\partial}{\partial w_j} \sum_i (\hat{y}^{[i]} - y^{[i]})^2 \\ &= \frac{\partial}{\partial w_j} \sum_i (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]})^2 \\ &= \sum_i 2(\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \frac{\partial}{\partial w_j} (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \\ &= \sum_i 2(\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \sigma'(\mathbf{w}^T \mathbf{x}^{[i]}) \frac{\partial}{\partial w_j} \mathbf{w}^T \mathbf{x}^{[i]} \\ &= \sum_i 2(\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \boxed{\sigma'(\mathbf{w}^T \mathbf{x}^{[i]})} x_j^{[i]} \end{aligned}$$

ADALINE (ADaptive Linear NEuron algorithm)

$$\mathcal{L}(\mathbf{w}, b) = \frac{1}{2n} \sum_i (\hat{y}^{[i]} - y^{[i]})^2 \quad \text{Mean Squared Error (MSE)}$$

$$\frac{\partial \mathcal{L}}{\partial w_j} = \frac{\partial}{\partial w_j} \frac{1}{2n} \sum_i (\hat{y}^{[i]} - y^{[i]})^2 \quad \sigma(z) = \frac{1}{1 + \exp(-z)} \quad \text{"output"} = \begin{cases} 1 & \text{if } a > 0.5 \\ 0 & \text{otherwise} \end{cases}$$

$$= \frac{\partial}{\partial w_j} \sum_i \frac{1}{2n} (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]})^2$$

$$= \sum_i \frac{1}{n} (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \frac{\partial}{\partial w_j} (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]})$$

$$= \frac{1}{n} \sum_i (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \frac{d\sigma}{d(\mathbf{w}^T \mathbf{x}^{[i]})} \frac{\partial}{\partial w_j} \mathbf{w}^T \mathbf{x}^{[i]}$$

$$= \frac{1}{n} \sum_i (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) \frac{d\sigma}{d(\mathbf{w}^T \mathbf{x}^{[i]})} x_j^{[i]}$$

$$= \frac{1}{n} \sum_i (\sigma(\mathbf{w}^T \mathbf{x}^{[i]}) - y^{[i]}) x_j^{[i]}$$

ADALINE (ADaptive Linear NEuron algorithm)

Метод стохастического градиента

Векторная форма

Алгоритм

1. Initialize $\mathbf{w} := 0^{m-1}$, $\mathbf{b} := 0$

2. For every training epoch:

A. For every $\langle \mathbf{x}^{[i]}, y^{[i]} \rangle \in \mathcal{D}$

$$(a) \hat{y}^{[i]} := \sigma(\mathbf{x}^{[i]T} \mathbf{w} + b)$$

$$(b) \nabla_{\mathbf{w}} \mathcal{L} = (y^{[i]} - \hat{y}^{[i]}) \mathbf{x}^{[i]} \\ \nabla_b \mathcal{L} = (y^{[i]} - \hat{y}^{[i]})$$

$$(c) \mathbf{w} := \mathbf{w} + \eta \times (-\nabla_{\mathbf{w}} \mathcal{L}) \\ b := b + \eta \times (-\nabla_b \mathcal{L})$$

learning rate $\nearrow$
 $\uparrow$
negative gradient

1. Initialize $\mathbf{w} := 0^{m-1}$, $\mathbf{b} := 0$

2. For every training epoch:

A. For every $\langle \mathbf{x}^{[i]}, y^{[i]} \rangle \in \mathcal{D}$

$$(a) \hat{y}^{[i]} := \sigma(\mathbf{x}^{[i]T} \mathbf{w} + b)$$

B. For weight j in $\{1, \dots, m\}$:


$$(b) \frac{\partial \mathcal{L}}{\partial w_j} = -(y^{[i]} - \hat{y}^{[i]}) x_j^{[i]}$$

$$(c) w_j := w_j + \eta \times \left(-\frac{\partial \mathcal{L}}{\partial w_j}\right)$$


$$C. \frac{\partial \mathcal{L}}{\partial b} = -(y^{[i]} - \hat{y}^{[i]}) \\ b := b + \eta \times \left(-\frac{\partial \mathcal{L}}{\partial b}\right)$$




Алгоритм обучения персептрона



Градиентный метод



Стохастический градиент



Градиент с минибатчами

Дельта-правило

Обучение нейрона по Дельта-правилу

1. Задать начальное состояние
2. Взять пример j из набора примеров
3. Вычислить выход нейрона для этого примера
4. Вычислить коррекцию синаптических весов для всех входов x_i
$$dw_i = - \eta (y(X_j) - d_j) x_i$$
5. Вычислить новый уровень w_i
$$w_i = w_i + dw_i$$
6. Перейти к новому примеру в п.2
7. Если просмотрели все примеры, то проверить условие конца (ошибка модели или число повторов):
 - условие выполнено - конец
 - условие не выполнено - начинаем просматривать примеры и изменять веса сначала ($j=0$) и к п.2.

Эпоха - просмотр всех примеров из набора

Пример с 1 нейроном

$$\mathcal{L} := 0, \quad w_1 := 0, \quad w_2 := 0, \quad b := 0$$

for i = 1 to i = n:

$$z^{[i]} = w^T x^{[i]} + b$$

$$a^{[i]} = \sigma(z^{[i]})$$

$$\mathcal{L} \pm (y^{[i]} - a^{[i]})^2$$

$$\frac{\partial \mathcal{L}}{\partial z^{[i]}} = -2(y^{[i]} - a^{[i]}) \cdot \sigma(z^{[i]})(1 - \sigma(z^{[i]}))$$

$$\frac{\partial \mathcal{L}}{\partial w_1} \pm x_1^{[i]} \frac{\partial \mathcal{L}}{\partial z^{[i]}}$$

$$\frac{\partial \mathcal{L}}{\partial w_2} \pm x_2^{[i]} \frac{\partial \mathcal{L}}{\partial z^{[i]}}$$

$$\frac{\partial \mathcal{L}}{\partial b} \pm \frac{\partial \mathcal{L}}{\partial z^{[i]}}$$

$$\mathcal{L} := \mathcal{L}/n$$


$$\frac{\partial \mathcal{L}}{\partial w_1} := \frac{\partial \mathcal{L}}{\partial w_1}/n, \quad \frac{\partial \mathcal{L}}{\partial w_2} := \frac{\partial \mathcal{L}}{\partial w_2}/n, \quad \frac{\partial \mathcal{L}}{\partial b} := \frac{\partial \mathcal{L}}{\partial b}/n$$

Многослойный персептрон

Слой

Множество слоев

$$y_j = f_j \left(\sum_{i=0,n} w_{ij} f_i \left(\sum_{k=0,m} w_{ki} x_k \right) \right)$$




Многослойный персептрон

Слой

Множество слоев

$$y_j = f_j \left(\sum_{i=0,n} w_{ij} f_i \left(\sum_{k=0,m} w_{ki} x_k \right) \right)$$




Нейронная сеть

Слой

Множество слоев

$$y_j = f_j \left(\sum_{i=0, n} w_{ij} f_i \left(\sum_{k=0, m} w_{ki} x_k \right) \right)$$



Теорема многослойного персептрона о разделимости классов

$T : \{x_i, y_i, i=1, n\},$

$$y_j = f_j \left(\sum_{i=0, n} w_{ij} f_i \left(\sum_{k=0, m} w_{ki} x_k \right) \right)$$

Для любой непрерывной функции $f(X) = f(x_1, x_2, \dots, x_n)$, определенной на ограниченной замкнутой области, и каждого $\varepsilon > 0$ существуют коэффициенты $w = (w_0, w_1, \dots, w_m)$ и $V_k = (V_{1k}, V_{2k}, \dots, V_{nk})$, h_k , $k = \overline{1, m}$, такие, что

$$\left| f(X) - \left(\sum_{k=1}^m w_k \cdot \sigma(V_{1k}x_1 + V_{2k}x_2 + \dots + V_{nk}x_n - h_k) + w_0 \right) \right| < \varepsilon.$$

$$\sum_{k=1}^m w_k \cdot \sigma(V_{1k}x_1 + V_{2k}x_2 + \dots + V_{nk}x_n - h_k) + w_0 = f_j \left(\sum_{i=0, n} w_{ij} f_i \left(\sum_{k=0, m} w_{ki} x_k \right) \right)$$

Теорема многослойного персептрона о разделимости классов

$$\left| f'(X) - \sum_{k=1}^m w_k \cdot \sigma'(V_k X - h_k) \right| < \varepsilon$$

Введем вейвлет

$$\psi(X) = \sigma'(X) - \sigma'(X - 1)$$

тогда последнее неравенство

$$\left| f'(X) - \sum_{k=1}^m c_k \cdot \psi(a_k(X - b_k)) \right| < \varepsilon$$

Пункт В. $n > 1$, $X = (x_1, x_2, \dots, x_n)$, $f(X) = f(x_1, x_2, \dots, x_n)$.

Из теории рядов Фурье следует, что любую функцию многих переменных $f(X) = f(x_1, x_2, \dots, x_n)$ можно представить в виде суммы функций одной переменной, то есть

$$f(X) \approx \sum_{k \in D} F_k \cdot e^{i(k, X)},$$

где $k \in D$, D — некоторое дискретное множество векторов $k = (k_1, k_2, \dots, k_n)$

Теорема многослойного персептрона о разделимости классов

Пункт А. $n = 1$, $X = (x_1)$. Для скалярного X имеем

$$\left| f(X) - \sum_{k=1}^m w_k \cdot \sigma(V_k X - h_k) \right| < \varepsilon$$

$$\left| f'(X) - \sum_{k=1}^m w_k \cdot \sigma'(V_k X - h_k) \right| < \varepsilon$$

Введем вейвлет

$$\psi(X) = \sigma'(X) - \sigma'(X - 1)$$

тогда последнее неравенство.

$$\left| f'(X) - \sum_{k=1}^m c_k \cdot \psi(a_k(X - b_k)) \right| < \varepsilon$$

Алгоритм обучения многослойного персептрона

$T : \{x_i, y_i, i=1, n\},$

$$y_j = f_j \left(\sum_{i=0, n} w_{ij} f_i \left(\sum_{k=0, m} w_{ki} x_k \right) \right)$$

W_{ji} – синаптические веса нейронов в j -й момент времени.

$$Y = X^T W$$

$e_i = y_i - \tilde{y}_i$ – сигнал ошибки

Функционал ошибок

$$E = \frac{1}{2} (Y - \widetilde{Y})^2$$

Задача – выбор вектора W , минимизирующего ошибку E

Алгоритм обратного распространения ошибки (backpropagation)

$$T : \{x_i, y_i, i=1, n\}, \quad y_j = f_j \left(\sum_{i=0, n} w_{ij} f_i \left(\sum_{k=0, m} w_{ki} x_k \right) \right)$$

W_{ji} – синаптические веса нейронов в j -й момент времени.

$$Y = X^T W$$



$e_i = y_i - \tilde{y}_i$ – сигнал ошибки

Функционал ошибок


$$E = \frac{1}{2} (Y - \tilde{Y})^2$$

Задача – выбор вектора W , минимизирующего ошибку E

Многослойный персептрон (решение проблемы XOR)



Многослойный персептрон с линейной функцией активации



Многослойный персептрон с нелинейной функцией активации