

Рекуррентные нейронные сети

ЛЕКЦИЯ №5



Темы

1. Архитектура RNN
2. Обучение рекуррентных сетей
3. Архитектура LSTM
4. Примеры

Рекуррентные нейронные сети RNN

Рекуррентные нейронные сети (Recurrent Neural Networks, RNN) – сети с обратными или перекрестными связями между различными слоями нейронов

Типовые примеры задач:

- Задачи распознавания речи: обработка последовательности звуков, обработка текстов естественного языка
- Задачи компьютерного зрения: обработка последовательности кадров видео, некоторые задачи обработки изображений.


Рекуррентная сеть аппроксимирует поведение динамических [систем.

Рекуррентные нейронные сети RNN. Граф вычислений.

Классическая форма динамической системы:


$$h^{(t)} = f(h^{(t-1)}; \theta),$$

где $h^{(t)}$ – состояние системы в момент времени t ,
 θ – множество параметров



Рекуррентная сеть


$$h^{(\tau)} = f(h^{(\tau-1)}; \theta) = f(f(h^{(\tau-2)}; \theta); \theta) = \dots = f(f(\dots f(h^{(1)}; \theta); \theta); \theta)$$




Рекуррентные нейронные сети RNN

Динамическая система, управляемая внешним сигналом $x^{(t)}$:

$$h^{(t)} = f(h^{(t-1)}; x^{(t)}; \theta)$$




Граф вычислений, развернутый во времени, для динамической системы, управляемой внешним сигналом имеет следующий вид:




Рекуррентные нейронные сети RNN

Динамическая система, управляемая внешним сигналом $x^{(t)}$:

$$h^{(t)} = f(h^{(t-1)}; x^{(t)}; \theta)$$



Recurrent Neural
Network (RNN)



Типовые шаблоны RNN

Рекуррентная нейронная сеть с зависимостью скрытых нейронов на себя является простейшей и называется рекуррентной сетью Элмана (Elman's network)


Рекуррентная сеть, обеспечивающая выходной сигнал на каждом временном шаге, и имеющая рекуррентные зависимости между элементами скрытого слоя



Типовые шаблоны RNN


Рекуррентная нейронная сеть с зависимостью скрытых нейронов на себя является простейшей и называется рекуррентной сетью Элмана (Elman's network)

Рекуррентная сеть, имеющая рекуррентные зависимости между элементами скрытого слоя, которая читает входную последовательность данных и обеспечивает единственный выходной сигнал



Типовые шаблоны RNN

Рекуррентная сеть, имеющая рекуррентные зависимости между выходным элементом текущего момента и скрытым элементом следующего момента, называется сетью Джордана (Jordan's network)



Обучение RNN

Уравнения, описывающие внутреннее состояние и выход сети, которая получена в результате развертывания сети Элмана во времени, имеют следующий вид:

$$\begin{aligned}a^{(t)} &= Ux^{(t)} + Wh^{(t-1)} + b, \\h^{(t)} &= f(a^{(t)}) = f(Ux^{(t)} + Wh^{(t-1)} + b), \\o^{(t)} &= Vh^{(t)} + c, \quad \tilde{y}^{(t)} = g(o^{(t)}) = g(Vh^{(t)} + c),\end{aligned}$$


где U, W, V – матрицы весов,

b, c – вектора сдвига,

$h^{(t)}$ – вектор скрытых переменных в момент t
(при обработке примера с номером t
из заданной входной последовательности),

$\tilde{y}^{(t)}$ – выход сети в момент t ,

$f(\cdot), g(\cdot)$ – функции активации



Обучение RNN

Задача обучения сети Элмана состоит в том, чтобы минимизировать суммарную ошибку по всем примерам имеющихся последовательностей:

$$J = \frac{1}{N} \sum_{n=1}^N \sum_{t=1}^{\tau_n} d\left(\tilde{y}_n^{(t)}, y_n^{(t)}\right) \rightarrow \min_{U, W, V} \quad ,$$

где N – количество входных последовательностей,
 τ_n – количество элементов последовательности с номером n ,
 $y_n^{(t)}$ – реальный выход (разметка) в момент t при рассмотрении последовательности с номером n ,
 $\tilde{y}_n^{(t)}$ – выход сети в момент t при получении входной последовательности с номером n ,
 $d\left(\tilde{y}_n^{(t)}, y_n^{(t)}\right)$ – мера сходства разметки и выхода сети

Обучение RNN

Рекуррентную нейронную сеть можно развернуть во времени, тем самым, представив ее в виде сети с прямым распространением сигнала

Для обучения параметров сети можно применить метод обратного распространения ошибки с разворачиванием сети во времени.


Вычисления в большинстве типовых рекуррентных сетей можно разложить на три блока параметров и соответствующих им преобразования:

- Преобразование входа в скрытое состояние
- Преобразование от предыдущего скрытого состояния в следующее скрытое состояние
- Преобразование скрытого состояния в выход

Типы RNN

Обычная рекуррентная сеть (a conventional RNN)

$$h^{(t)} = f(Ux^{(t)} + Wh^{(t-1)} + b), \quad \tilde{y}^{(t)} = g(Vh^{(t)} + c)$$




Типы RNN





Рекуррентная сеть с глубоким преобразованием входного сигнала в скрытый (Deep Transition RNN, DT-RNN)

$$h^{(t)} = f(Ux^{(t)} + Wh^{(t-1)} + b)$$
$$= \varphi_L \left(U_L^T \varphi_{L-1} \left(U_{L-1}^T \varphi_{L-2} \left(\dots \varphi_1 (Ux^{(t)} + Wh^{(t-1)} + b) \right) \right) \right),$$


где L – количество слоев сети между входным и скрытым слоями



Типы RNN




Backpropagation through time RNN



Werbos, Paul J. "Backpropagation through time: what it does and how to do it."

RNN с одним скрытым слоем

Матрица весовых коэффициентов



Вход в блок

$$\mathbf{z}_h^{(t)} = \mathbf{W}_{hx} \mathbf{x}^{(t)} + \mathbf{W}_{hh} \mathbf{h}^{(t-1)} + \mathbf{b}_h$$

Активационная функция

$$\mathbf{h}^{(t)} = \sigma_h(\mathbf{z}_h^{(t)})$$

Выход блока


$$\mathbf{z}_y^{(t)} = \mathbf{W}_{yh} \mathbf{h}^{(t)} + \mathbf{b}_y$$

Выходной слой

$$\mathbf{y}^{(t)} = \sigma_y(\mathbf{z}_y^{(t)})$$


Werbos, Paul J. "Backpropagation through time: what it does and how to do it."

Backpropagation through time



Werbos, Paul J. "Backpropagation through time: what it does and how to do it."

Backpropagation through time




$$L = \sum_{t=1}^T L^{(t)} \quad \frac{\partial L^{(t)}}{\partial \mathbf{W}_{hh}} = \frac{\partial L^{(t)}}{\partial y^{(t)}} \cdot \frac{\partial y^{(t)}}{\partial \mathbf{h}^{(t)}} \cdot \left(\sum_{k=1}^t \frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(k)}} \cdot \frac{\partial \mathbf{h}^{(k)}}{\partial \mathbf{W}_{hh}} \right)$$

$$\frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(k)}} = \prod_{i=k+1}^t \frac{\partial \mathbf{h}^{(i)}}{\partial \mathbf{h}^{(i-1)}}$$

Werbos, Paul J. "Backpropagation through time: what it does and how to do it."

НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ


Блок LSTM



Werbos, Paul J. "Backpropagation through time: what it does and how to do it."


НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ

Блок LSTM



НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ


Блок LSTM



НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ

Блок LSTM Gate забвения

$$f_t = \sigma \left(\mathbf{W}_{fx} \mathbf{x}^{\langle t \rangle} + \mathbf{W}_{fh} \mathbf{h}^{\langle t-1 \rangle} + \mathbf{b}_f \right)$$




НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ

Блок LSTM Gate входа

"Input Gate": $i_t = \sigma \left(\mathbf{W}_{ix} \mathbf{x}^{(t)} + \mathbf{W}_{ih} \mathbf{h}^{(t-1)} + \mathbf{b}_i \right)$

"Input Node":

$$\mathbf{g}_t = \tanh \left(\mathbf{W}_{gx} \mathbf{x}^{(t)} + \mathbf{W}_{gh} \mathbf{h}^{(t-1)} + \mathbf{b}_g \right)$$




НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ

Блок LSTM Gate входа

"Input Gate": $i_t = \sigma \left(\mathbf{W}_{ix} \mathbf{x}^{(t)} + \mathbf{W}_{ih} \mathbf{h}^{(t-1)} + \mathbf{b}_i \right)$

"Input Node":

$$\mathbf{g}_t = \tanh \left(\mathbf{W}_{gx} \mathbf{x}^{(t)} + \mathbf{W}_{gh} \mathbf{h}^{(t-1)} + \mathbf{b}_g \right)$$




НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ

Блок LSTM

Forget Gate Input Node Input Gate


$$C^{<t>} = \left(C^{<t-1>} \odot f_t \right) \oplus \left(i_t \odot g_t \right)$$



НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ


Выходной сигнал

$$\mathbf{o}_t = \sigma \left(\mathbf{W}_{ox} \mathbf{x}^{(t)} + \mathbf{W}_{oh} \mathbf{h}^{(t-1)} + \mathbf{b}_o \right)$$




НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ

Выход




$$h^{<t>} = o_t \odot \tanh \left(c^{<t>} \right)$$



НЕЙРОННЫЕ СЕТИ ДОЛГОЙ КРАТКОВРЕМЕННОЙ ПАМЯТИ

Gated Recurrent Unit (GRU)



S, Kyunghyun, Ba Merriënboer, C Gulcehre, and Yoshua Bengio. "Learning phrase representations using RNN encoder-decoder for statistical machine translation." arXiv preprint arXiv:1406.1078 (2014)