

Лекция 6. Автокодировщики

План лекции

- 1. Автокодировщики (AE)**
- 2. Архитектура автокодировщиков.**
- 3. Обучение автокодировщиков.**
- 4. Вариационные автоэнкодеры (VAE)**
- 5. Вариационные автоэнкодеры с условием (CVAE)**
- 1. Автокодировщики (AE)**

Идея автокодировщиков исторически является частью ландшафта нейронных сетей уже несколько десятилетий (LeCun, 1987; Bourlard and Kamp, 1988; Hinton and Zemel, 1994). Традиционно их использовали для понижения размерности и обучения признакам.

Автокодировщики можно рассматривать как частный случай сетей прямого распространения и обучать, применяя те же методы, обычно мини-пакетный градиентный спуск в направлении градиентов, вычисленных в ходе обратного распространения.

В 2006 году архитектура автокодировщика была описана в работе Джеффри Хинтона и Салахутдинова «Reducing the Dimensionality of Data with Neural Networks» в 2006 году. Авторы предложили метод преобразования данных высокой размерности в низкоразмерные коды путем обучения многослойной нейронной сети с небольшим центральным слоем. Предложенную архитектуру нейронных сетей – «автокодировщики», обучали методом градиентного спуска. Преимущество предложенной архитектуры заключается в снижении размерности входных данных, что облегчает решение задач классификации, визуализации, коммуникации и хранения высокоразмерных данных.

Автокодировщик (англ. autoencoder) – специальная архитектура искусственных нейронных сетей, позволяющая применять обучение без учителя при использовании метода обратного распространения ошибки.

Автокодировщики успешно применялись в задачах понижения размерности и информационного поиска. Понижение размерности было одним из первых приложений обучения представлений и глубокого обучения, а также одним из ранних стимулов к изучению автокодировщиков. Представления низкой размерности могут повысить качество во многих задачах, в т. ч. классификации. Чем меньше пространство, тем меньше памяти занимает модель и тем быстрее производятся расчеты.

Типы автоэнкодеров:

- глубокие автоэнкодеры (AE);
- сверточные автоэнкодеры;
- разреженные автоэнкодеры (SAE)

- Denoising Autoencoders (DAE)
- вариационные автокодировщики (VAE);
- вариационные автокодировщики с условием (CVAE).

Применения автокодировщика:

Предобучение.

В тех случаях, когда для обучения с учителем обучающая выборка мала, однако в распоряжении есть объем неразмеченных данных, то можно на большой неразмеченной выборке настроить автокодировщик

$$f(x)=d(e(x))f(x)=d(e(x)),$$

а затем инициализировать первые слои сети, решающей задачу обучения с учителем слоями кодировщика. Таким образом, можно провести перевод объектов из исходного пространства низкоуровневых признаков в высокоуровневые, с которыми проще работать.

Снижение размерности.

Если размерность пространства скрытого слоя (эмбеддингов) существенно меньше размерности исходного пространства признаков, то объекты можно хранить не в исходном виде, а в сжатом - в виде эмбеддинга. Чтобы восстановить сжатый объект до исходного, достаточно просто пропустить его через декодировщик $x=d(e(x))x=d(e(x))$.

Поскольку автокодировщик неидеально восстанавливает исходный объект, получим сжатие данных с потерями (lossy compression), которое часто используется на практике, как, например, при представлении изображений в JPEG формате.

Визуализация данных

Является частным случаем снижения размерности, когда размерность эмбеддинга равна двум или трём. Используется для визуализации сложных многомерных данных.

Фильтрация шума (denoising)

Один из эффективных методов, используемых в качестве предобработки изображений в задачах компьютерного зрения. Реализуется путем пропускания зашумлённого объекта (например, изображения с шумом) через автокодировщик. Удаление шума обеспечивается тем, что автокодировщик хорошо восстанавливает типичные паттерны реальных данных, а шум случаен, поэтому его сложно воспроизвести. Архитектура автокодировщика - denoising autoencoder.

Детекция аномалий (anomaly detection)

Метод, используемый для поиска аномалий (выбросов). Решает задачу в которой нужно выделить нетипичные объекты, выбивающиеся из общего распределения объектов.

Генерация новых данных по заданному образцу

Метод, используемый для генерации новых данных — данных из другого распределения, отличающегося от общего распределения объектов.

Автокодировщики

Автоэнкодер (Autoencoder –AE) — специальная архитектура искусственных нейронных сетей, позволяющая применять обучение без учителя (рисунок 1).

Копирование входа в выход может показаться бесполезным делом, но, как правило, нас не интересует выход декодера. Вместо этого мы надеемся, что, обучая автокодировщик задаче копирования входа, мы получим код h , обладающий полезными свойствами. Один из способов получить такие свойства — наложить ограничение, согласно которому размерность h должна быть меньше размерности x . Такие автокодировщики называются понижающими (undercomplete). Обучение понижающего представления заставляет автокодировщик улавливать наиболее отличительные признаки обучающих данных. Процесс обучения описывается просто как минимизация функции потерь.




Рисунок 1

Разреженный автоэнкодер (Sparse autoencoder SAE) — тип архитектуры нейронных сетей, предназначенный для решения проблемы интерпретируемости путем обеспечения разреженности в скрытых слоях сети (рисунок 2).

Разреженным называется автокодировщик, для которого критерий обучения включает штраф разреженности $\Omega(h)$ на кодовом слое h в дополнение к ошибке реконструкции.

Разреженные автокодировщики чаще всего применяются для обучения признакам в интересах другой задачи, например классификации. Автокодировщик, регуляризованный с целью добиться разреженности, должен откликаться на уникальные статистические особенности набора данных, на котором обучался, а не просто выступать в роли тождественной функции. Поэтому обучение копированию со штрафом разреженности может дать модель, которая попутно обучилась каким-то полезным признакам.




Рисунок 2

Вариационный автоэнкодер (Variational Autoencoder – VAE) — автокодировщик (генеративная модель, которая учится отображать объекты в заданное скрытое пространство и обратно), основанный на вариационном выводе (рисунок 3).

Вариационные автоэнкодеры относятся к семейству генеративных моделей и используются для генерации изображений.




Рисунок 3

Вариационный автоэнкодер с условием — автокодировщик основанный на вариационном выводе, который накладывает условия на входное пространство (рисунок 4).

Вариационные автоэнкодеры с условием также относятся к семейству генеративных моделей и используются для генерации изображений.




Рисунок 4

Шумоподавляющий автокодировщик (DAE)

Шумоподавляющий автокодировщик (DAE) – автокодировщик, который получает на входе искаженные данные и обучается предсказывать истинные, не искаженные данные

За последнее десятилетие использование изображений значительно возросло. Изображения искажаются шумом в процессе получения, сжатия и передачи. Окружающая среда, каналы передачи и другие каналы являются средами, через которые изображения искажаются шумом. При обработке изображений шум изображения представляет собой изменение сигнала (в случайной форме), которое влияет на яркость или цвет наблюдения изображения и извлечения информации. Шум отрицательно влияет на задачи обработки изображений (такие как обработка видео, анализ изображений и сегментация), что приводит к неправильной диагностике. Следовательно, шумоподавление изображения является фундаментальным аспектом, который усиливает понимание задачи обработки изображений.

Методы шумоподавления изображений используются в области медицинской визуализации, дистанционного зондирования, военного наблюдения, биометрии и судебной экспертизы, промышленной и сельскохозяйственной автоматизации, а также для распознавания лиц.

В настоящее время процесс восстановления информации из зашумленных изображений для получения чистого изображения является проблемой неотложной важности. Процедуры шумоподавления изображений удаляют шум и восстанавливают чистое изображение. Основная проблема при шумоподавлении изображений заключается в том, как различать шум, края и текстуру (поскольку все они имеют высокочастотные компоненты). Использование специальной архитектуры нейронных сетей -

автокодировщиков показало отличные результаты для шумоподавления реальных шумных изображений и многих других.

2. Архитектура автокодировщика

Автокодировщик (англ. autoencoder) – специальная архитектура искусственных нейронных сетей, позволяющая применять обучение без учителя при использовании метода обратного распространения ошибки.

Обучение без учителя (Unsupervised) используется для извлечения низкоразмерного представления признаков на основе немаркированных обучающих данных

Автокодировщиком называется нейронная сеть, обученная пытаться скопировать свой вход в выход. На внутреннем уровне в ней имеется скрытый слой h , который описывает код, используемый для представления входа. Можно считать, что сеть состоит из двух частей: функция кодирования - энкодер $h = f(x)$ и декодер, порождающий реконструкцию $r = g(h)$. Эта архитектура показана на рисунке 5.




Рисунок 5

Если автокодировщику удастся просто обучиться всюду сохранять тождество $g(f(x)) = x$, то это не особенно полезно.

На самом деле автокодировщики проектируются так, чтобы они не могли обучиться идеальному копированию. Обычно налагаются ограничения, позволяющие копировать только приближенно и только тот вход, который похож на обучающие данные. Поскольку модель заставляют расставлять подлежащие копированию аспекты данных по приоритетам, то часто она обучается полезным свойствам данных.

В современных автокодировщиках идея кодировщика и декодера обобщена с вероятностным подходом

$p_{\text{encoder}}(h | x)$ и $p_{\text{decoder}}(x | h)$, где p_{encoder} – условная вероятность.

Цель обучения автокодировщиков: найти внутреннюю структуру в данных.

Обучение автокодировщиков относится к методам машинного обучения без учителя.

Таким образом, при обучении кодировщика отсутствует учитель – метки принадлежности к классу и минимизируется функция потерь L^2 – функция потерь, которая описывает сходство (различие) изображения на входе X – входные данные и выходе $\hat{X}$ – выходные данные. В качестве функции потерь можно взять MAE или MSE. Обучение происходит таким образом, чтобы выявить особенности, необходимые для восстановления исходных данных. (рисунок 6)




Рисунок 6.

X – входные данные;

$\hat{X}$ – выходные данные;

Z – скрытое пространство признаков (латентное пространство).

L^2 – функция потерь.

Рассмотрим простейший пример сверточного автоэнкодера

Архитектура автоэнкодера

Используются слои свертки **Conv2D** и слои снижения размерности **MaxPooling2D**.

Блоки в энкодере идентичны

Состав блока энклдера:

- Двумерная свертка.
- Нормализация.
- Двумерная свертка.
- Нормализация.
- Снижение размерности.

Каждый блок завершается слоем **MaxPooling2D**, который уменьшает размерность данных.

Архитектура декодера

2 блока декодера, представляющие собой обратные действия для энкодера.

Состав блока декодера:

- Повышение размерности.
- Нормализация.
- Двумерная свертка.
- Нормализация
- Двумерная свертка.
- Нормализация.

После двух блоков декодера идет финальный слой двумерной свертки декодера, который выдает итоговое изображение.

Шумоподавляющие кодировщики

С увеличением применения количества цифровых изображений, снятых в плохих условиях, методы шумоподавления изображений стали необходимым инструментом для компьютерного анализа. В настоящее время процесс восстановления информации из зашумленных изображений для получения чистого изображения является проблемой неотложной важности. Процедуры шумоподавления изображений удаляют шум и восстанавливают чистое изображение. Основная проблема при шумоподавлении изображений заключается в том, как различать шум, края и текстуру (поскольку все они имеют высокочастотные компоненты). Наиболее обсуждаемым шумом в литературе является: аддитивный белый гауссовский шум (AWGN), импульсный шум, шум квантования, пуассоновский шум и спекл-шум.

Методы шумоподавления изображений используются в области медицинской визуализации, дистанционного зондирования, военного наблюдения, биометрии и судебной экспертизы, промышленной и сельскохозяйственной автоматизации, а также для распознавания лиц. В медицинской и биомедицинской визуализации алгоритмы шумоподавления являются основными этапами предварительной обработки, используемыми для удаления медицинского шума, такого как спекл, Райс, квантовый и другие.

В дистанционном зондировании алгоритмы шумоподавления используются для удаления соли и перца, а также аддитивного белого гауссовского шума. Изображения с синтезированной апертурой радара (SAR) обеспечивают космические и воздушные операции в военном наблюдении. Методы шумоподавления изображений использовались для фильтрации листьев риса и обнаружения болезней растений риса. Несомненно, шумоподавление изображений является важной областью исследований, охватывающей

различные сферы академической деятельности (Methods for image denoising using convolutional neural network: a review

<https://link.springer.com/article/10.1007/s40747-021-00428-4>)

Наиболее часто встречающиеся виды шумов:

- аддитивный белый гауссовский шум (AWGN),
- импульсный шум,
- шум квантования,
- шум Пуассона,
- спекл-шум.

Гауссовский шум возникает в аналоговых схемах, в то время как импульсный, спекл-, пуассоновский и квантовый шум возникают из-за неисправного производства, битовой ошибки и недостаточного количества фотонов.

Линейные, нелинейные и неадаптивные фильтры были первыми фильтрами, которые использовались для приложений обработки изображений.

Классические фильтры шумоподавления подразделяются на шесть категорий:

- линейные,
- нелинейные,
- адаптивные, основанные на вейвлетах,
- фильтры частных дифференциальных уравнений (PDE),
- фильтры полной вариации).

Линейные фильтры сопоставляют выходные пиксели с входными соседними пикселями (используя процедуру умножения матриц) для снижения шума.

Нелинейные фильтры сохраняют информацию о краях и по-прежнему подавляют шум. В большинстве приложений фильтрации нелинейный фильтр используется вместо линейного фильтра. Линейный фильтр не сохраняет информацию о краях; поэтому он считается плохим методом фильтрации. Простым примером нелинейного фильтра является медианный фильтр (MF).

Адаптивные фильтры используют статистические компоненты для приложений в реальном времени (примерами являются наименьшее среднеквадратичное и рекурсивное среднеквадратичное).

Фильтры на основе вейвлетов преобразуют изображения в область вейвлетов и используются для снижения аддитивного шума. Подробный обзор различных фильтров шумоподавления доступен в литературе.

Большинство из вышеупомянутых фильтров дали достаточно хорошие результаты, однако у них есть некоторые недостатки. К этим недостаткам относятся плохая

оптимизация фазы тестирования, ручная настройка параметров и определенные модели шумоподавления.

Гибкость сверточных нейронных сетей (CNN) показала способность решать эти недостатки. Алгоритмы CNN способны решать многие проблемы. Например, CNN достигли превосходных результатов в распознавании изображений, робототехнике, беспилотном вождении, выражении лица, распознавании рукописного цифрового текста и многих других областях.

Чан и Салливан были первыми, кто использовал CNN (глубокое обучение) для задач шумоподавления изображений. Нейронная сеть использовалась для удаления сложного шума, затем сеть прямого распространения обеспечивала баланс между эффективностью и производительностью шумоподавленного изображения.

(<https://link.springer.com/article/10.1007/s40747-021-00428-4>)

Метрики для оценки качества изображений

Оценка качества восстановленных изображений может быть выполнена с использованием различных метрик, которые измеряют степень точности восстановления в сравнении с исходными изображениями. Некоторые из наиболее распространенных метрик включают:

Среднеквадратичная ошибка (MSE): вычисляет среднеквадратичную разницу между каждым пикселем исходного и восстановленного изображений. Чем ниже значение, тем лучше восстановление.

$$MSE = \frac{1}{N} ||I - L||^2$$

Пиковое отношение к шуму (PSNR): измеряет отношение максимально возможной силы сигнала к уровню шума, вызванному восстановлением. Чем выше PSNR, тем лучше качество изображения.

$$PSNR = 10 * \log_{10} \left(\frac{(\max(I))^2}{MSE} \right)$$

Структурное сходство (SSIM): учитывает не только ошибку яркости, но и ошибки в структуре изображения. Значение SSIM близкое к 1 указывает на высокое сходство между изображениями.

Восприимчивость к внешним искажениям (LPIPS): измеряет восприимчивость человеческого визуального восприятия к искажениям изображений.

Косинусное сходство (Cosine Similarity): оценивает сходство между векторами интенсивности пикселей исходного и восстановленного изображений.

Геометрические метрики: включают такие метрики, как структурное сходство (аналогичное SSIM), а также меры, оценивающие изменения в геометрии или деталях изображения после восстановления.

Выбор метрики зависит от контекста задачи и природы изображений. Оценка качества обычно проводится с использованием нескольких метрик, чтобы получить более полное представление о качестве восстановления.

Структурное сходство (SSIM): учитывает не только ошибку яркости, но и ошибки в структуре изображения. Значение SSIM близкое к 1 указывает на высокое сходство между изображениями.

$$SSIM(u, v) = \frac{(2\mu_I\mu_L + Q_1)(2\sigma_{IL} + Q_2)}{(\mu_I^2 + \mu_L^2 + Q_1)(\sigma_I^2 + \sigma_L^2 + Q_2)}$$

Q_1, Q_2 small positive constants

Восприимчивость к внешним искажениям (LPIPS): измеряет восприимчивость человеческого визуального восприятия к искажениям изображений.

Сверточные архитектуры автокодировщиков представлены на рисунке. 7.




Рисунок 7.

Архитектуры автокодировщика Attention-guided CNN (ADNet) представлена на рисунке. 8.




Рисунок 8.

Архитектуры автокодировщика MP-DCNN представлена на рисунке. 9.




Рисунок 9.

Архитектуры автокодировщика DeGAN Denoising-based generative adversarial network представлена на рисунке. 10.

Denoising-based generative adversarial network (DeGAN) удаляет смешанные шумы.

DeGAN включает генератор, дискриминатор, feature extractor network.

Генератор - U-Net architecture,

дискриминатор - 10 end-to-end слоев.

Основная задача дискриминатора – проверка присутствия шума на изображении, оцененном U-Net (extractor network).

Итоговая, the feature extraction network - VGG19 используется для оценки изображения и для расчета loss function




Рисунок 10.